Domaći zadatak 3- Vizualizacija i eksploracija u Orange

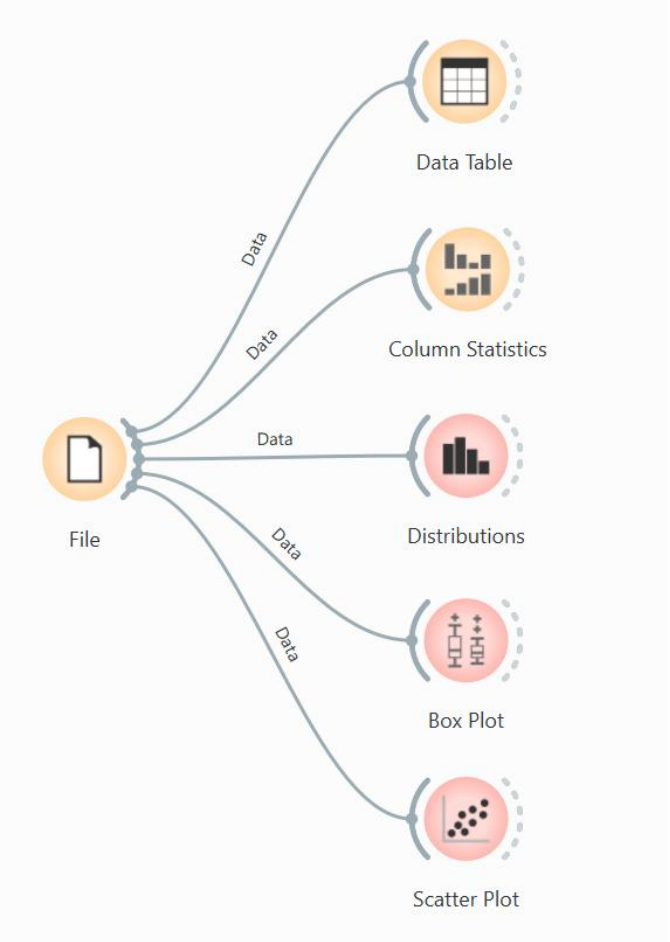
Katarina Gordić 41/2023 RN

Uvod

Za potrebe ovog domaćeg zadatka korišćen je eksterni dataset ***Nutritional Facts for Most Common Foods***, koji sadrži nutritivne informacije o različitim namirnicama, uključujući podatke o kalorijama, količini proteina, masti, ugljenih hidrata i drugih nutritivnih komponenti. Dataset je preuzet sa Kaggle platforme (`kaggle.com/datasets/niharika41298/nutrition-details-for-most-common-foods`) i učitan u Orange Data Mining alat putem CSV fajla.

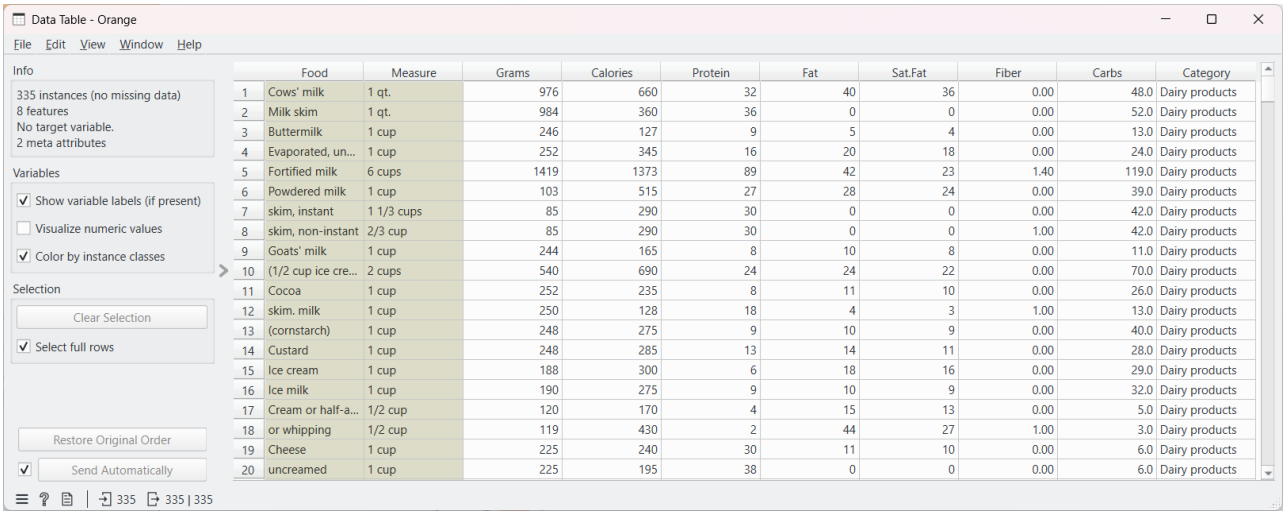
Pre početka analize izvršeno je minimalno čišćenje podataka kako bi dataset bio pogodan za obradu u Orange-u. U pojedinim nutritivnim kolonama pojavljivale su se oznake poput "t" (trace amounts – količine u tragovima), koje su zamenjene nulama kako bi promenljive mogle biti tretirane kao numeričke. Takođe, ispravljena je jedna očigledna greška nastala automatskim formatiranjem datuma u Excel-u, a proverene su i ostale vrednosti koje su mogle uticati na pravilno prepoznavanje tipova podataka.

Workflow

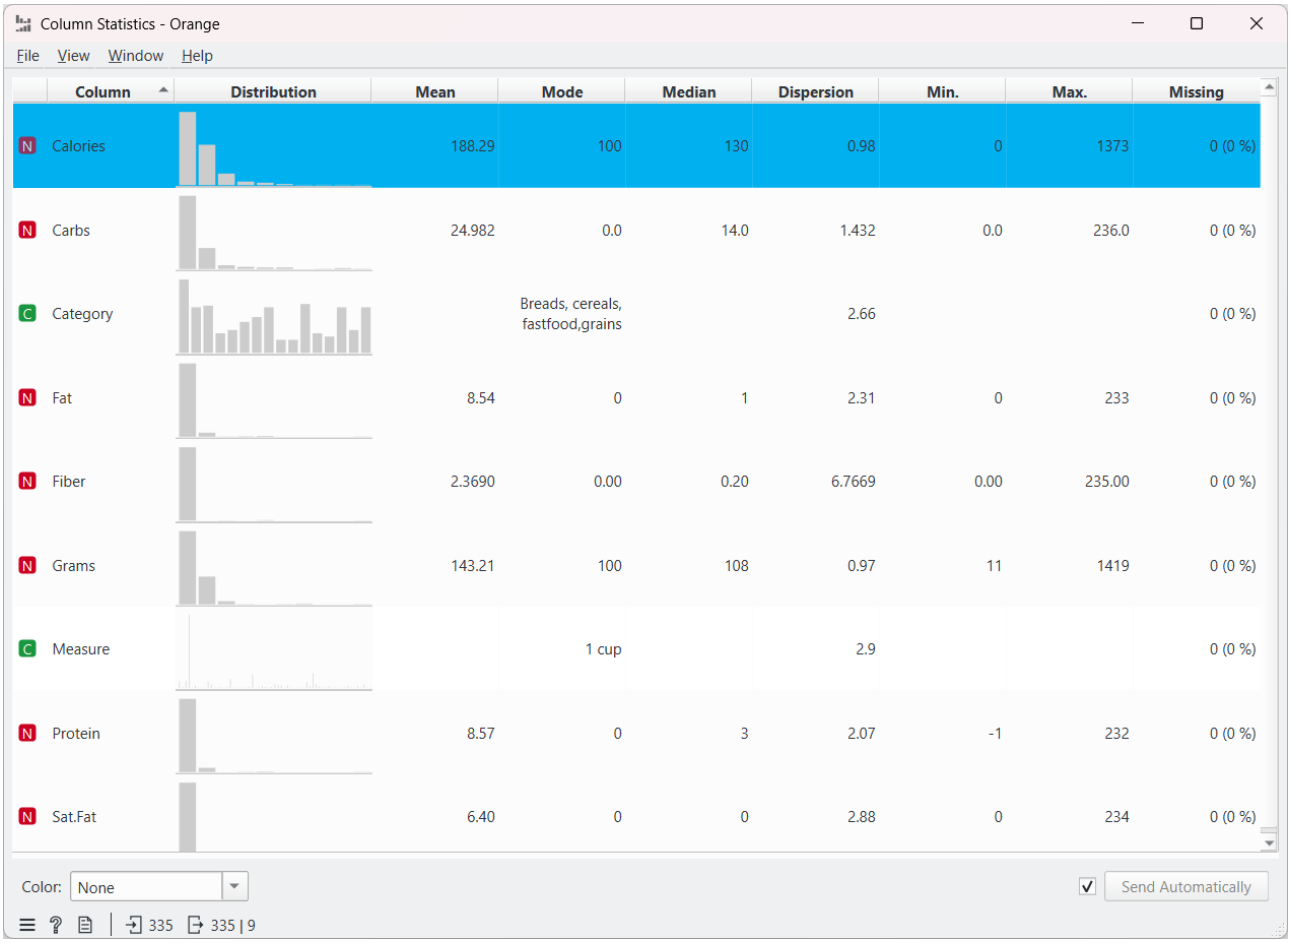


Analiza

1. DataTable i Feature Statistics



	Food	Measure	Grams	Calories	Protein	Fat	Sat.Fat	Fiber	Carbs	Category
1	Cows' milk	1 qt.	976	660	32	40	36	0.00	48.0	Dairy products
2	Milk skim	1 qt.	984	360	36	0	0	0.00	52.0	Dairy products
3	Buttermilk	1 cup	246	127	9	5	4	0.00	13.0	Dairy products
4	Evaporated, un...	1 cup	252	345	16	20	18	0.00	24.0	Dairy products
5	Fortified milk	6 cups	1419	1373	89	42	23	1.40	119.0	Dairy products
6	Powdered milk	1 cup	103	515	27	28	24	0.00	39.0	Dairy products
7	skim, instant	1 1/3 cups	85	290	30	0	0	0.00	42.0	Dairy products
8	skim, non-instant	2/3 cup	85	290	30	0	0	1.00	42.0	Dairy products
9	Goats' milk	1 cup	244	165	8	10	8	0.00	11.0	Dairy products
10	(1/2 cup ice cre...	2 cups	540	690	24	24	22	0.00	70.0	Dairy products
11	Cocoa	1 cup	252	235	8	11	10	0.00	26.0	Dairy products
12	skim. milk	1 cup	250	128	18	4	3	1.00	13.0	Dairy products
13	(cornstarch)	1 cup	248	275	9	10	9	0.00	40.0	Dairy products
14	Custard	1 cup	248	285	13	14	11	0.00	28.0	Dairy products
15	Ice cream	1 cup	188	300	6	18	16	0.00	29.0	Dairy products
16	Ice milk	1 cup	190	275	9	10	9	0.00	32.0	Dairy products
17	Cream or half-a...	1/2 cup	120	170	4	15	13	0.00	5.0	Dairy products
18	or whipping	1/2 cup	119	430	2	44	27	1.00	3.0	Dairy products
19	Cheese	1 cup	225	240	30	11	10	0.00	6.0	Dairy products
20	uncreamed	1 cup	225	195	38	0	0	0.00	6.0	Dairy products



Column	Distribution	Mean	Mode	Median	Dispersion	Min.	Max.	Missing
Calories		188.29	100	130	0.98	0	1373	0 (0 %)
Carbs		24.982	0.0	14.0	1.432	0.0	236.0	0 (0 %)
Category			Breads, cereals, fastfood,grains		2.66			0 (0 %)
Fat		8.54	0	1	2.31	0	233	0 (0 %)
Fiber		2.3690	0.00	0.20	6.7669	0.00	235.00	0 (0 %)
Grams		143.21	100	108	0.97	11	1419	0 (0 %)
Measure			1 cup		2.9			0 (0 %)
Protein		8.57	0	3	2.07	-1	232	0 (0 %)
Sat.Fat		6.40	0	0	2.88	0	234	0 (0 %)

- Pitanje 1: Koliko opservacija i varijabli ima vaš dataset? Koliko je numeričkih, a koliko kategorijskih varijabli? Ima li nedostajućih vrednosti?

Dataset sadrži **335** opservacija i **10** varijabli. Od ukupnog broja varijabli:

- 7 su numeričke
- 2 su kategorijske (*Category* i *Measure*)
- jedna varijabla (*Food*) tekstualnog tipa.

U Orange-u je **8** promenljivih definisano kao feature atributi koji se koriste u analizama, dok su 2 promenljive (*Food* i *Measure*) postavljene kao meta atributi. Nakon pripreme i čišćenja podataka, u konačnoj verziji dataseta nisu identifikovane nedostajuće vrednosti.

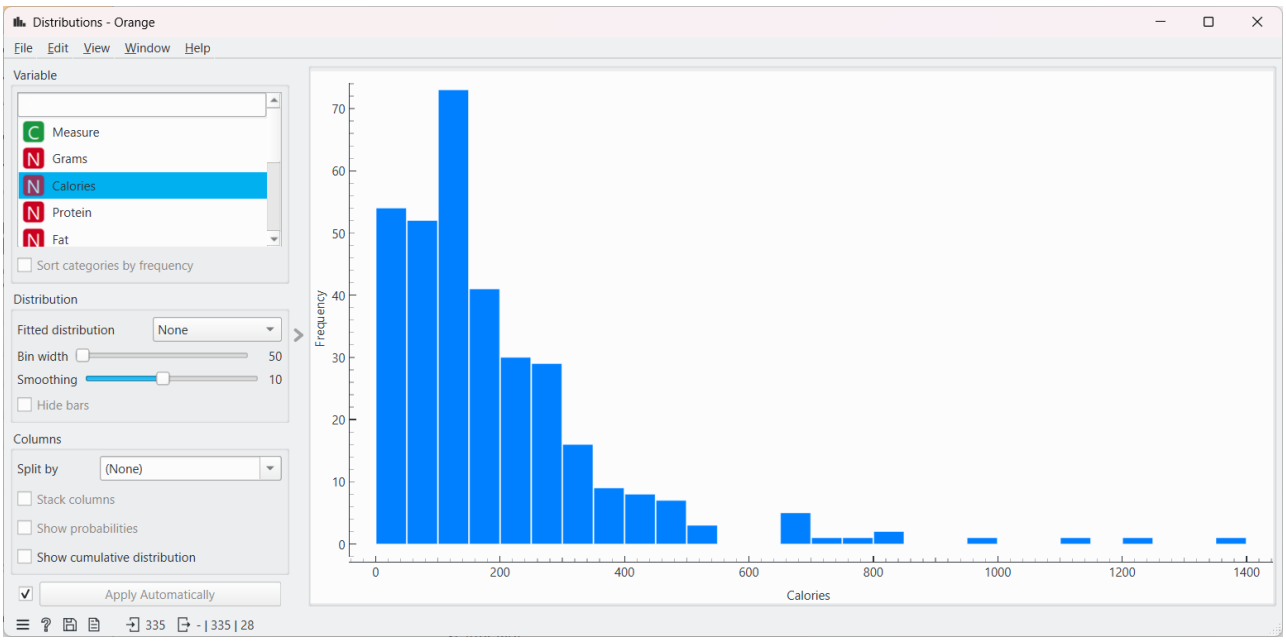
- Pitanje 2: Koja varijabla ima najveći raspon vrednosti? Da li to ima smisla za tu varijablu?

Najveći raspon vrednosti ima varijabla **Grams**, sa vrednostima od 11 do 1419 g. Ovakav rezultat je očekivan, jer različite namirnice imaju veoma različite veličine porcija, pa se količina izražena u gramima značajno razlikuje među posmatranim primerima.

---

2. Distributions

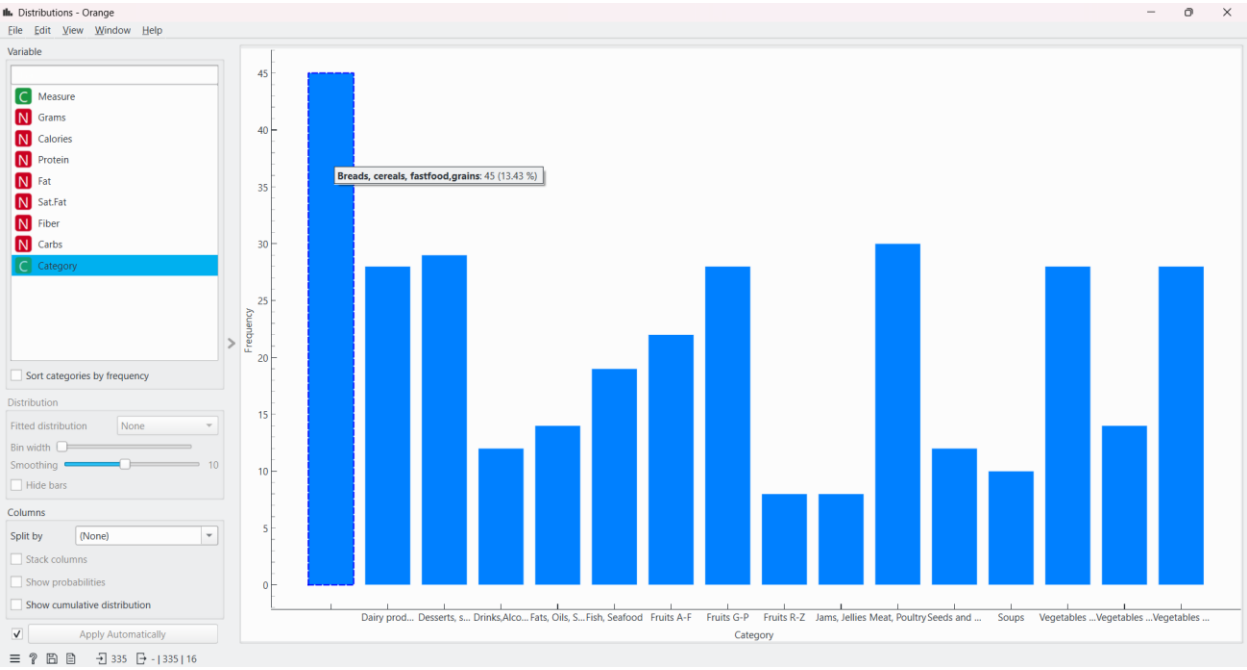
- Pitanje 3: Kako izgleda raspodela ključne numeričke varijable? Da li liči na Normalnu raspodelu ili je iskošena? Šta to može da znači za dalju analizu?





Raspodela promenljive **Calories** ne liči na normalnu raspodelu, već je **pozitivno (udesno) iskošena**. Većina namirnica ima niži do umeren broj kalorija, dok manji broj namirnica ima veoma visoke kalorijske vrednosti, što se vidi po produženom repu raspodele ka većim vrednostima. Ovakva raspodela može ukazivati na prisustvo autlajera i sugeriše da bi u slučaju statističkog poređenja grupa možda bilo potrebno koristiti neparametarske testove umesto testova koji pretpostavljaju normalnost podataka.

- Pitanje 4: Koja kategorija se najčešće pojavljuje u kategorijskoj varijabli? Da li je to očekivano?

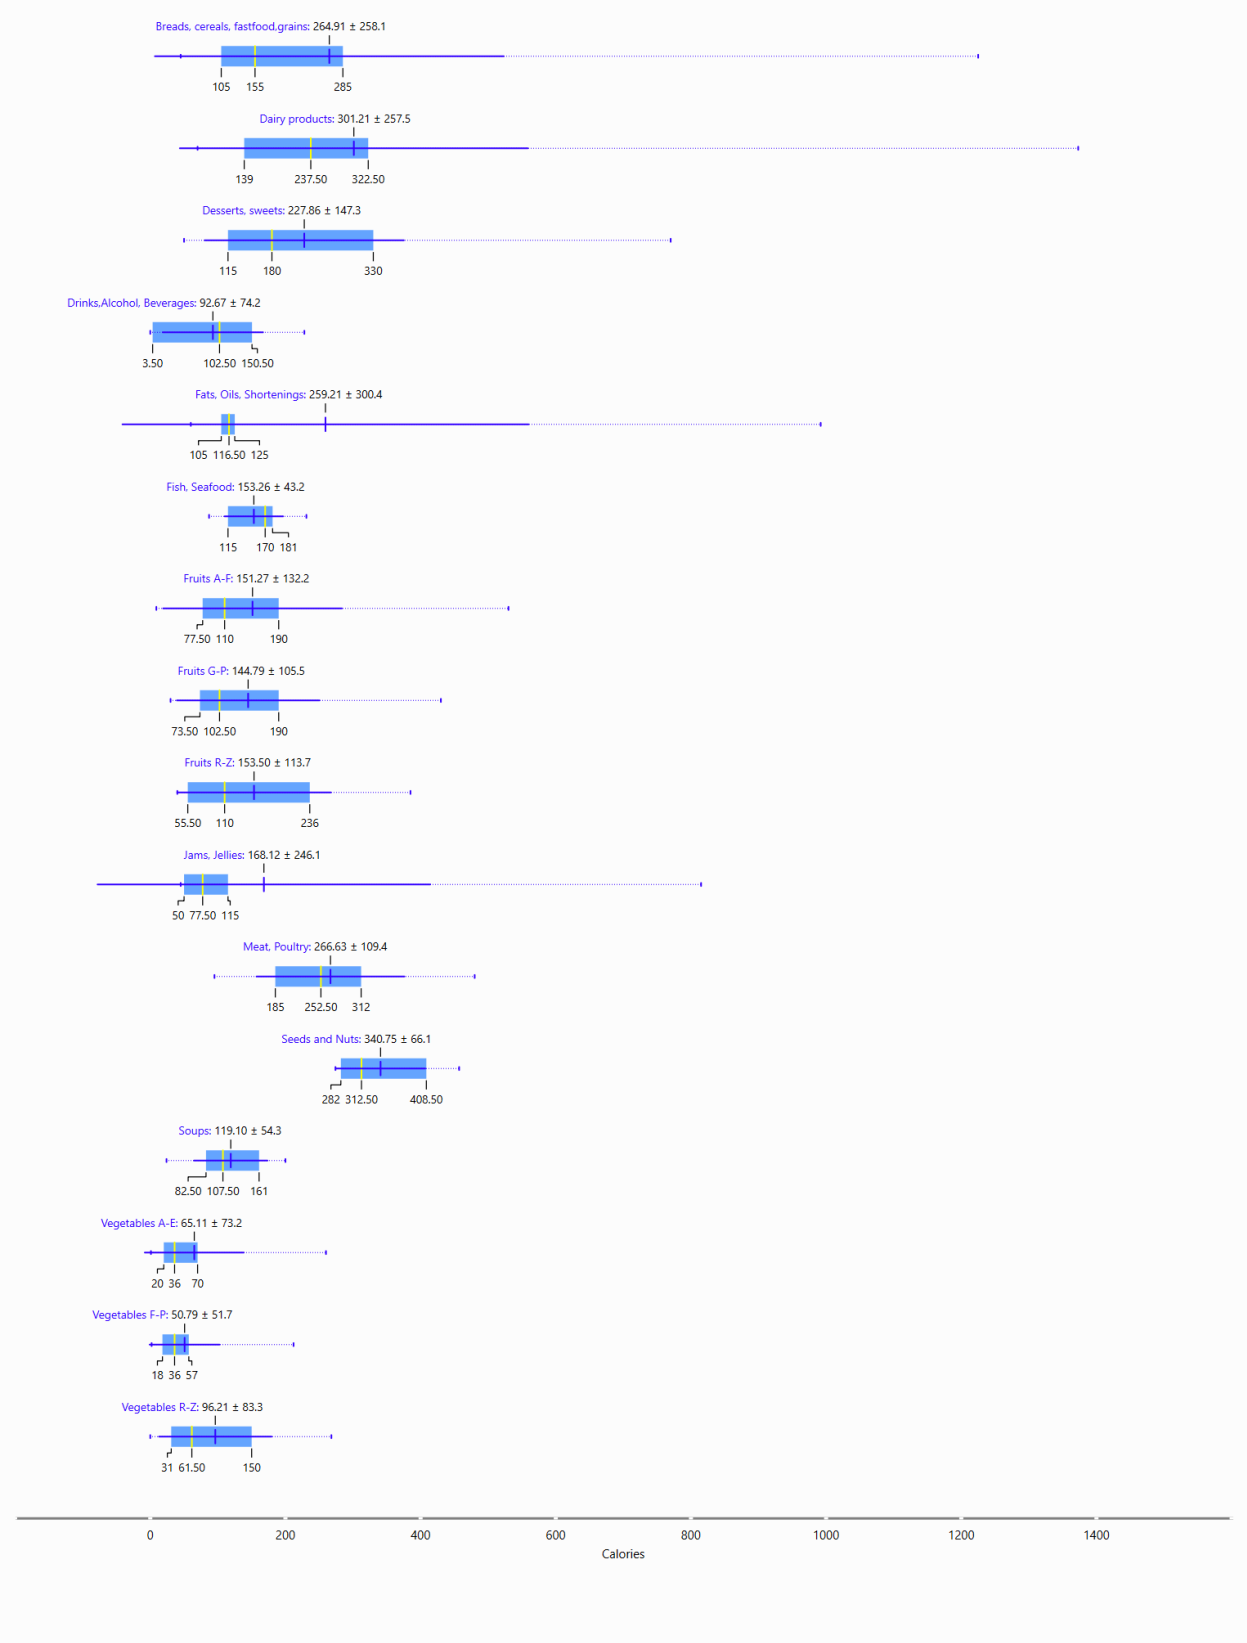


U okviru promenljive **Category**, najčešće se pojavljuje kategorija **"Breads, cereals, fastfood, grains"**, koja obuhvata 45 namirnica (13.43% ukupnog broja opservacija). Ovakav rezultat je očekivan, jer ova kategorija uključuje veliki broj različitih proizvoda. Ipak, treba imati u vidu da dataset predstavlja skup nutritivnih informacija o uobičajenim namirnicama, pa zastupljenost pojedinih kategorija ne mora nužno odražavati stvarne prehrambene navike populacije.

---

3. Box Plot

Box plot prikazuje raspodelu **kalorijskog sadržaja** (**Calories**) u različitim **kategorijama hrane** (**Category**). Na ovaj način moguće je uporediti tipične vrednosti kalorija, stepen varijabilnosti unutar svake kategorije i prisustvo potencijalnih autlajera.


Breads, cereals, fastfood.grains: 264.91 ± 258.1
105 155 285
Dairy products: 301.21 ± 257.5
139 237.50 322.50
Desserts, sweets: 227.86 ± 147.3
115 180 330
Drinks,Alcohol, Beverages: 92.67 ± 74.2
3.50 102.50 150.50
Fats, Oils, Shortenings: 259.21 ± 300.4
105 116.50 125
Fish, Seafood: 153.26 ± 43.2
115 170 181
Fruits A-F: 151.27 ± 132.2
77.50 110 190
Fruits G-P: 144.79 ± 105.5
73.50 102.50 190
Fruits R-Z: 153.50 ± 113.7
55.50 110 236
Jams, Jellies: 168.12 ± 246.1
50 77.50 115
Meat, Poultry: 266.63 ± 109.4
185 252.50 312
Seeds and Nuts: 340.75 ± 66.1
282 312.50 408.50
Soups: 119.10 ± 54.3
82.50 107.50 161
Vegetables A-E: 65.11 ± 73.2
20 36 70
Vegetables F-P: 50.79 ± 51.7
18 36 57
Vegetables R-Z: 96.21 ± 83.3
31 61.50 150
0 200 400 600 800 1000 1200 1400
Calories

- Pitanje 5: Koja grupa ima najveću varijansu (najširu kutiju)? Koja je najkompaktnija?

Širina kutije predstavlja interkvartilni raspon (IQR), odnosno raspon u kojem se nalazi srednjih 50% vrednosti. Što je kutija šira, to je veća varijabilnost unutar te grupe. Najveću varijabilnost među posmatranim kategorijama pokazuje grupa **Desserts, sweets**, koja ima najširu kutiju, što ukazuje da se kalorijski sadržaj različitih poslastica značajno razlikuje.

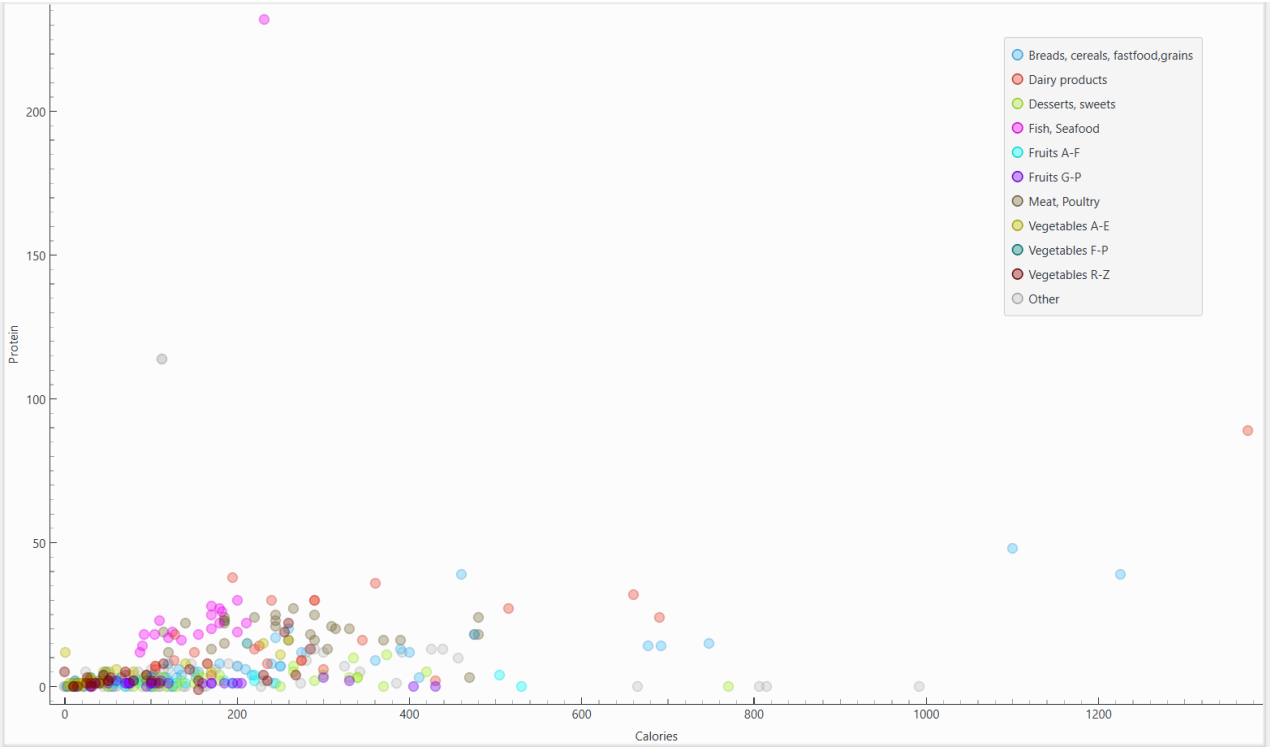
Sa druge strane, najkompaktnija grupa je **Fat, Oils, Shortenings**, koja ima najužu kutiju i najmanji interkvartilni raspon. To znači da su kalorijske vrednosti srednjih 50% namirnica iz ove kategorije relativno ujednačene, iako se u grupi mogu pojavljivati i ekstremne vrednosti.

- Pitanje 6: Ima li autlajera? Ako da — da li su to greške u podacima ili realne ekstremne vrednosti?

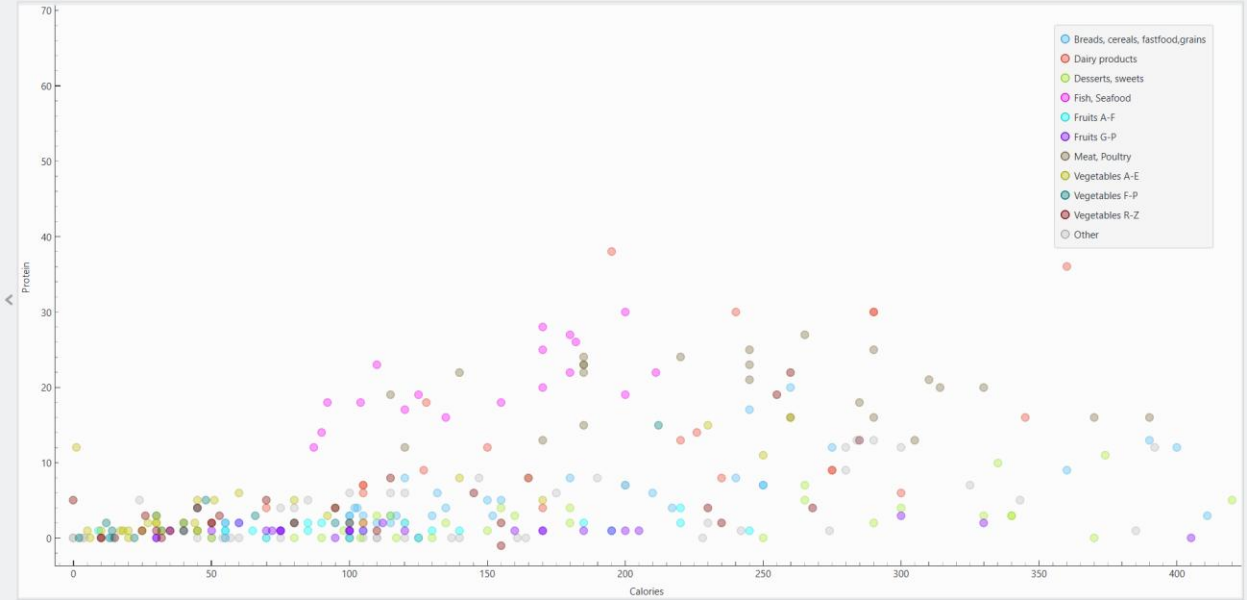
Na box plotu mogu se uočiti autlajeri, odnosno vrednosti koje značajno odstupaju od ostatka podataka unutar pojedinih kategorija hrane. Najizraženiji autlajeri primećeni su u kategorijama **Dairy products**, **Breads, cereals, fastfood, grains** i **Fat, Oils, Shortenings**, što se vidi po veoma dugim isprekidanim linijama koje predstavljaju ekstremne vrednosti. Ovi autlajeri najverovatnije ne predstavljaju greške u podacima, već realne karakteristike određenih namirnica. Na primer, pojedini mlečni proizvodi, fast food obroci ili namirnice bogate mastima i uljima mogu imati znatno veći kalorijski sadržaj od proseka svoje kategorije. Zbog toga se izdvajaju na box plotu kao ekstremne, ali i dalje realne vrednosti.

---

4. Scatter Plot



Calories vs Protein



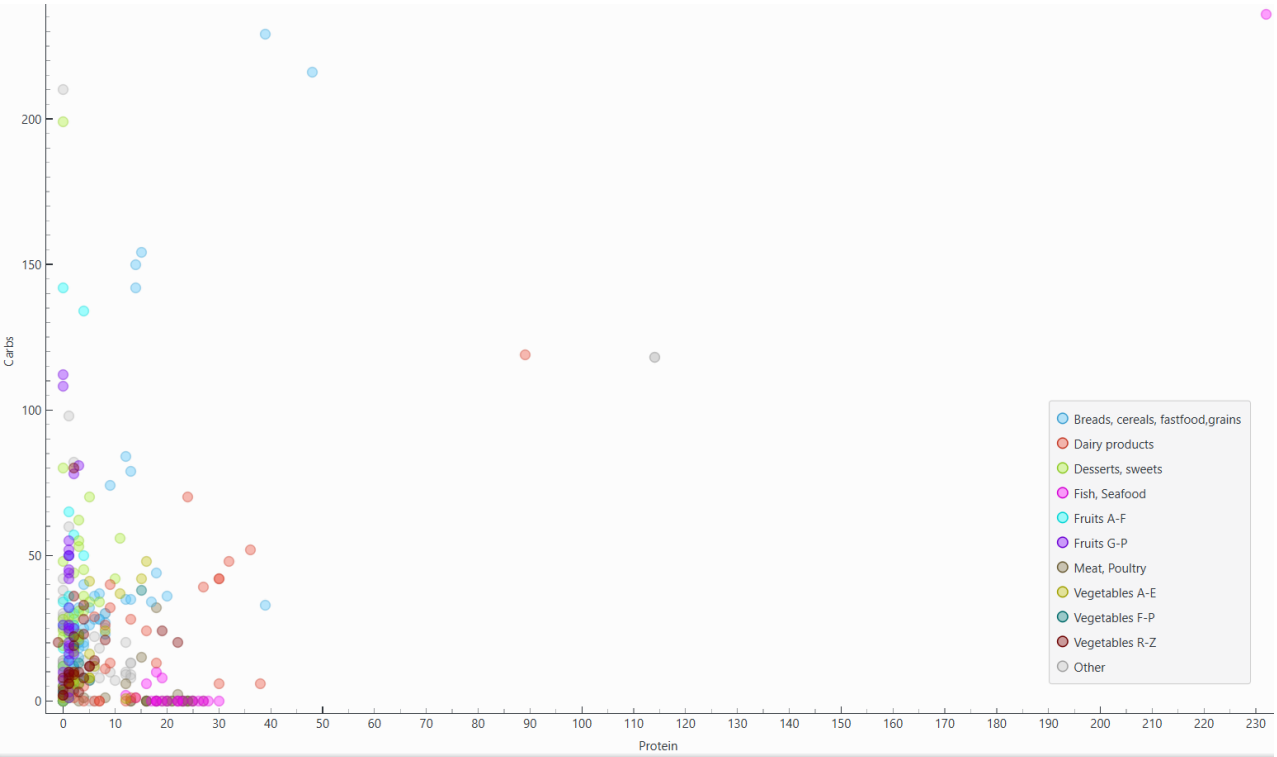
Zoom in
Calories vs Protein

- Pitanje 7a: Da li postoji vidljiva veza između varijabli koje ste izabrali? Opišite je jednom rečenicom.

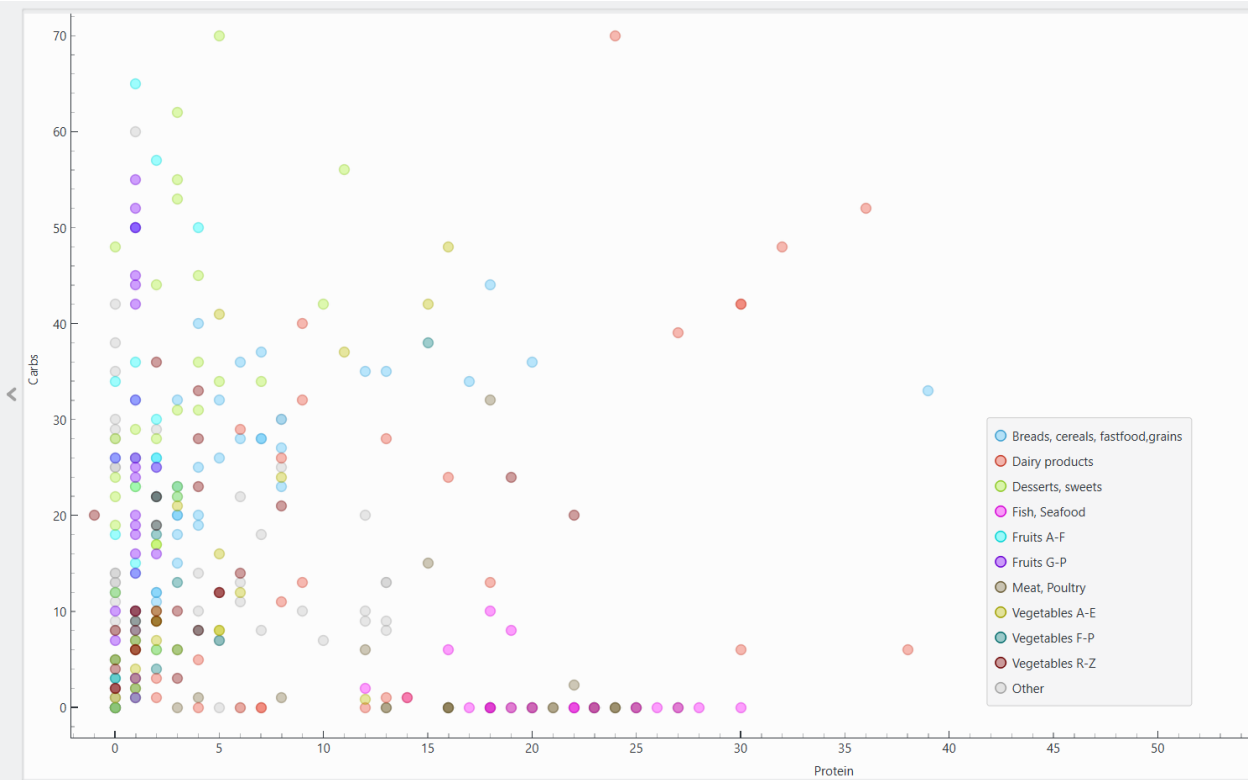
Između broja kalorija i količine proteina može se uočiti **blaga pozitivna povezanost**. Generalno, namirnice sa većim kalorijskim sadržajem imaju tendenciju da sadrže više proteina, ali veza nije jaka jer postoji veliko rasipanje podataka. Mnoge namirnice sa sličnim brojem kalorija imaju veoma različit sadržaj proteina, što ukazuje da kalorijska vrednost zavisi i od drugih nutritivnih komponenti, poput masti i ugljenih hidrata.

- Pitanje 8a: Da li boja (kategorijska varijabla) otkriva nešto zanimljivo u scatter plotu — da li se grupe razdvajaju?

Bojenje tačaka po kategorijama hrane ne pokazuje potpuno razdvajanje grupa, jer se većina kategorija međusobno preklapa. Ipak, mogu se uočiti određeni obrasci. Na primer, kategorije **Fish, Seafood** i **Meat, Poultry** češće se pojavljuju pri višim vrednostima proteina, dok se mnoge kategorije voća i povrća uglavnom nalaze u delu grafikona sa nižim sadržajem proteina. Boja zato pomaže u prepoznavanju opštih tendencija, ali nije dovoljna za jasno razdvajanje svih grupa.



Protein vs Carbs



Zoom in
Protein vs Carbs

- Pitanje 7b: Da li postoji vidljiva veza između varijabli koje ste izabrali? Opišite je jednom rečenicom.

Na scatter plotu nije uočena jaka povezanost između količine proteina i ugljenih hidrata. Može se primetiti blaga tendencija da namirnice sa većim sadržajem proteina imaju manju količinu ugljenih hidrata i obrnuto, ali zbog velikog rasipanja podataka ova veza nije izražena. To ukazuje da sadržaj proteina i ugljenih hidrata u namirnicama zavisi od vrste hrane i njenog nutritivnog sastava.

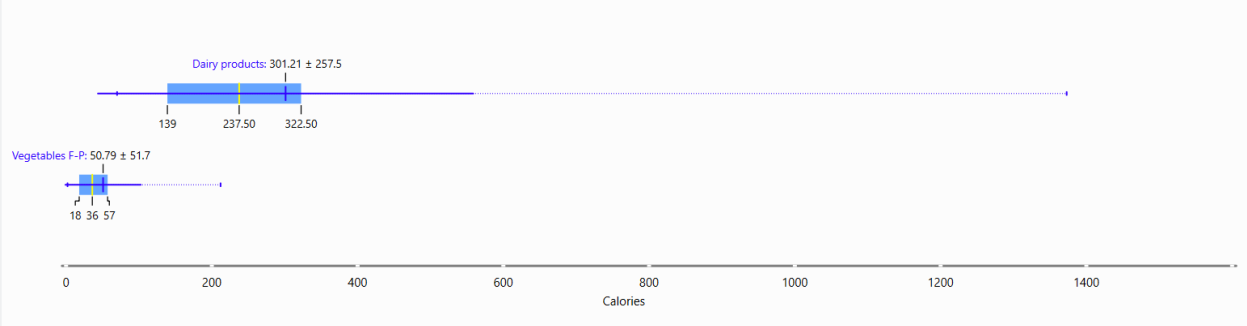
- Pitanje 8b: Da li boja (kategorijska varijabla) otkriva nešto zanimljivo u scatter plotu — da li se grupe razdvajaju?

Bojenje tačaka prema kategorijama hrane otkriva određene obrasce i delimično razdvajanje grupa. Kategorije **Fish, Seafood** i **Meat, Poultry** uglavnom se nalaze u delu grafikona sa većim sadržajem proteina i manjom količinom ugljenih hidrata, što odgovara njihovom nutritivnom sastavu. Sa druge strane, kategorije poput **Breads, cereals, fastfood, grains** i **Desserts, sweets** češće se pojavljuju pri višim vrednostima ugljenih hidrata. Iako se kategorije međusobno preklapaju i ne mogu se potpuno razdvojiti, boja omogućava uočavanje karakterističnih nutritivnih profila različitih grupa namirnica.

Analitička pitanja

- Pitanje 9 — Poređenje: Izaberite dve grupe unutar vaše kategorijske varijable i uporedite ih po jednoj numeričkoj varijabli. Koja grupa ima više vrednosti i kolika je razlika?







Za poređenje su izabrane kategorije **Dairy products** i **Vegetables F–P**, a analizirana je numerička varijabla **Calories**. Na osnovu box plota može se uočiti da mlečni proizvodi imaju znatno veći kalorijski sadržaj od povrća. Medijana kalorijske vrednosti za mlečne proizvode iznosi **237,5 kcal**, dok za povrće iz kategorije Vegetables F–P iznosi **36 kcal**. Razlika između medijana iznosi približno **201,5 kcal**, što ukazuje da su mlečni proizvodi u ovom skupu podataka u proseku mnogo kaloričniji od posmatrane kategorije povrća.

- Pitanje 10 — Kritika grafika: Pogledajte jedan od vaših grafika i zamislite da ga vidite po prvi put. Da li je lako čitljiv? Šta biste promenili — naslov, boje, tip grafika? Zašto?

Kao primer za kritiku izabrala sam Box Plot koji prikazuje raspodelu kalorijskog sadržaja po svim kategorijama hrane. Kada bih ovaj grafik videla po prvi put, ne bih ga smatrala naročito preglednim, jer veliki broj kategorija otežava poređenje grupa, a pojedini natpisi i detalji se teško uočavaju. Grafik bih unapredila korišćenjem kontrastnih boja i kraćih naziva kategorija, kao i prikazivanjem manjeg broja kategorija odjednom ili njihovim podelama u više zasebnih grafika. Na taj način bi poređenje između grupa bilo jednostavnije, a zaključci jasniji i lakši za interpretaciju. Takođe, za osobe koje nisu upoznate sa ovakvim prikazom podataka, pregledniji bi mogao biti jednostavniji tip grafika, poput stubičastog dijagrama.

- Pitanje 11 — Veza sa kursom: Da li raspodela vaše ključne numeričke varijable izgleda Normalna? Šta bi to značilo da smo ovu analizu radili u R-u — koji test bismo koristili za poređenje grupa?

Raspodela kalorijskog sadržaja ne izgleda normalno, već je iskošena udesno, sa velikim brojem namirnica koje imaju niže kalorijske vrednosti i manjim brojem veoma kaloričnih namirnica. Da smo ovu analizu radili u R-u, prvo bismo proverili pretpostavku normalnosti, na primer **Shapiro–Wilk testom**. Ukoliko bi se pokazalo da podaci ne prate normalnu raspodelu, ne bi bilo opravdano koristiti parametarske testove poput ANOVA-e. Umesto toga, za poređenje više nezavisnih grupa koristili bismo **Kruskal–Wallis test**, koji ne zahteva pretpostavku normalnosti podataka i zasniva se na rangovima, a ne na samim vrednostima. Nakon dobijanja statistički značajnog rezultata, bilo bi potrebno sprovesti i odgovarajući **post hoc test** kako bi se utvrdilo između kojih grupa postoje razlike. S obzirom na veliki broj kategorija hrane i prisustvo ekstremnih vrednosti, izbor neparametarskog pristupa bio bi posebno opravdan u ovom slučaju.